

未知度合いと把持量のばらつきを考慮したサンプリング最適化と把持位置選択による食品把持の高精度化

旅田 海聖† 岡本直樹† 平川 翼† 山下 隆義† 藤吉 弘亘†

† 中部大学

E-mail: kaisei51@mprg.cs.chubu.ac.jp

1 はじめに

食品製造工場における惣菜等の詰め込み作業は人手で行われており、ピッキングロボットによる自動化が求められている。ポテトサラダ等の総菜は不定形状であるため、把持戦略を事前に設計することは難しい。そこで、データドリブンな深層学習を用いて把持戦略を決定する必要がある。高橋らは、学習データの不足に基づく不確実性を考慮した把持手法 [1] や食品特有の形状に基づく不確実性を考慮した把持手法 [2] を提案している。この2つの手法は、推論時にモデルの予測の不確実性が低い領域（モデルの予測の信頼性が高い領域）を把持位置として選択することで、小数の学習データを用いた場合の把持精度の向上を実現した。

予測の不確実性とは、確率的な要因で発生する予測のばらつきである。例えば、学習データに含まれていない状況やデータ数が少ない状況に対して、モデルは誤った予測を行う可能性がある。また、千切りキャベツやもやしのような食品の把持は、食品同士が絡まる可能性があるため、食品の状態によって把持量が変化する。このように、収集したデータや把持対象等の様々な要因によって、モデルの予測にはばらつきが発生する。しかしながら、従来の把持手法 [1, 2] はそれぞれ1つの観点のみに基づいた不確実性を考慮している。

そこで本研究では、従来の把持手法 [1, 2] と同様に不確実性を考慮した把持位置選択を行うが、その際に複数の観点に基づいた不確実性を考慮する手法を提案する。不確実性が低い領域の把持位置選択は、モデルの自信が高い領域のみに対して把持を行うことを意味する。そのため、学習時に不確実性が低い領域を優先的に学習することで、少数の学習データにおける把持精度を向上させる手法を提案する。評価実験では、物体間で絡まりが発生しやすい疑似食品として輪ゴムを把持対象とする。不確実性に基づいてピッキングロボットの把持位置を選択し、モデルが予測した把持量とピッキングロボットの把持量を比較することで、従来手法と提案手法による把持精度の評価を行う。

2 関連研究

本章では、形状に基づいた把持手法、深層学習を用いた把持手法、不確実性を考慮した食品の把持手法について述べる。

2.1 形状に基づいた把持

形状に基づいた把持は、物体の3D形状データや視覚情報を活用して、安定した把持位置を決定する。物体の3D形状データを用いたシミュレーション環境の構築 [3] や物体の3D形状が把持の安定性に与える影響の分析 [4] 等が行われている。これらの形状に基づいた把持は、未知の物体に対して事前に把持計画を立てることが難しい。また、ポテトサラダのような不定形状な物体に対しては、形状から適切な把持位置を決定することが難しい。

2.2 深層学習を用いた把持

深層学習を用いた把持は、カメラ画像や点群データを入力とし、ニューラルネットワークを用いて適切な把持位置を予測する。深層学習を用いることで、未知の物体に対しても高い汎化性能を発揮することが知られている。深層強化学習 [5] による把持動作の学習 [6] では、ポリシーネットワーク [7] による把持成功率の最大化や、LSTM [8] による過去の試行結果の活用が行われた。しかし、これらの深層強化学習を用いた把持は、大量の試行回数が必要であり、多くの時間とコストを必要とする。そこで、シミュレーションベースの学習手法 [9] が提案されている。シミュレーション環境内で大量の把持データを生成し、CNN [10] を学習する。シミュレーション環境で事前に大規模なデータを生成することで、実機のロボットによる試行回数を削減できる。しかし、実環境とのギャップによる問題 [11] が生じる可能性がある。

2.3 不確実性を考慮した食品把持

深層学習を用いた把持手法の多くは、ペットボトル等の大きな物体を対象としており、煮豆等の小さな食品やポテトサラダ等の不定形状な食品の把持は困難である。また、食品製造工場では季節や新商品等によって扱う食品の種類や形状が頻繁に変わるため、大量の

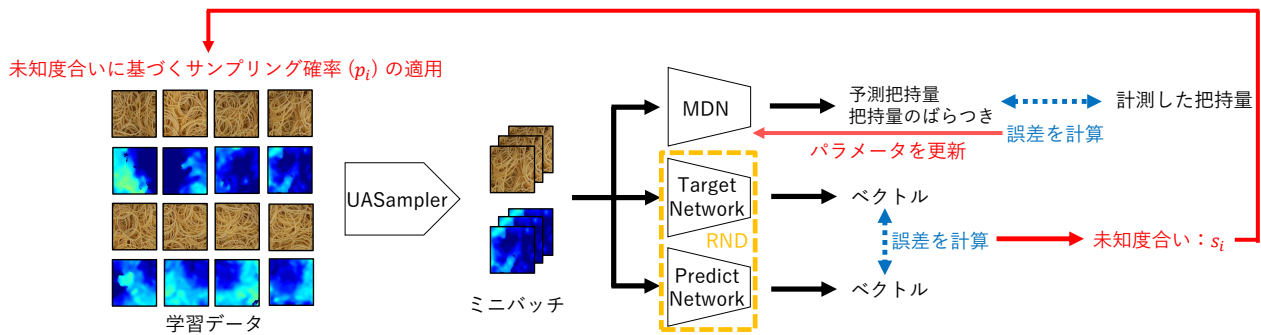


図 1: モデル構造と未知度合いに基づいたサンプリングを導入した学習方法

データを集めて特定の食品に特化したモデルを用意することは困難である。そこで、少量の学習データを用いてモデルを学習し、モデルの出力に基づいて把持位置を選択する手法として、学習データの不足に基づく不確実性を考慮した把持 [1] や食品特有の形状に基づく不確実性を考慮した把持 [2] が提案されている。これらの手法では、食品の把持量を予測する問題において、モデルにより把持量と不確実性を予測する。学習したモデルを用いて把持位置を選択する際は、目標の把持量に近く、不確実性が低い領域を選択することで、学習時に見たことのない状態の領域や把持が難しい領域を避け、把持精度の向上を実現した。

3 提案手法

不確実性を考慮した食品把持手法 [1, 2] は、不確実性が低い領域を把持位置として選択することで、学習データ数が少ない場合における把持精度の向上を実現した。不確実性には学習データの不足による不確実性や食品特有の形状による不確実性等の複数の観点が存在する。しかし、従来の食品把持手法 [1, 2] は把持位置の選択時に 1 つの観点に基づいた不確実性しか考慮していない。また、不確実性が低い領域を把持位置として選択する戦略は、不確実性が高い領域に関する学習が把持精度に影響しない。そこで、本研究では不確実性が低い学習データを優先的に学習する戦略と、複数の不確実性に基づいた把持位置の選択を提案する。

3.1 モデル構造と学習方法

不確実性を考慮可能なモデルとして、食品特有の形状による不確実性を考慮した食品把持手法 [2] で提案された Mixture Density Network (MDN) [12] に基づいたモデルと、学習データ不足による不確実性を考慮した食品把持手法 [1] で提案された Random Network Distillation (RND) [13] に基づいたモデルを使用する。2つのモデルを使用したモデル構造とモデルの学習方法を図 1 に示す。

MDN は、カメラ画像と深度情報を入力とし、把持量

と把持量のばらつきを出力する。MDN では、予測把持量を混合ガウス分布で表現して学習することで、把持量のばらつきを出力可能とする。MDN の出力を式 (1) に示す。

$$P(O'_{\text{mass}}) = \sum_{k=1}^K \Pi_k \phi(O'_{\text{mass}} | \mu_k, \sigma_k) \quad (1)$$

ここで、 O'_{mass} は予測把持量、 K はガウス分布の数、 Π_k はガウス分布の混合係数、 ϕ はガウス関数、 μ_k は平均値、 σ_k は標準偏差である。MDN はガウス分布の混合係数 Π_k 、平均値 μ_k 、標準偏差 σ_k を出力し、混合ガウス分布の負の対数尤度を最小化するように学習する。MDN の出力を用いた損失式を式 (2) に示す。

$$L_{\text{MDN}} = -\log \left[\sum_{k=1}^K \Pi_k \phi(O_{\text{mass}} | \mu_k, \sigma_k) \right] \quad (2)$$

ここで、 O_{mass} は正解となる把持量である。

RND は、乱数で初期化した重みパラメータで固定された Target Network と、学習により重みパラメータを更新する Predict Network から構成される。各 Network はカメラ画像と深度情報を入力としてベクトルを出力する。Predict Network は、Target Network の出力と一致するように学習する。Target Network は、乱数で初期化した重みパラメータで固定されているため、Predict Network と Target Network の差が大きいほど、カメラ画像や深度情報の状態が学習時に見たことのない状態であることを意味する。RND の損失式を式 (3) に示す。

$$L_{\text{RND}} = \|v_{\text{target}} - v_{\text{predict}}\|^2 \quad (3)$$

ここで、 v_{target} は Target Network の出力ベクトル、 v_{predict} は Predict Network の出力ベクトルである。

MDN と RND は同じ学習データを用いて同時に学習を行う。最終的な損失関数を式 (4) に示す。

$$L = L_{\text{MDN}} + L_{\text{RND}} \quad (4)$$

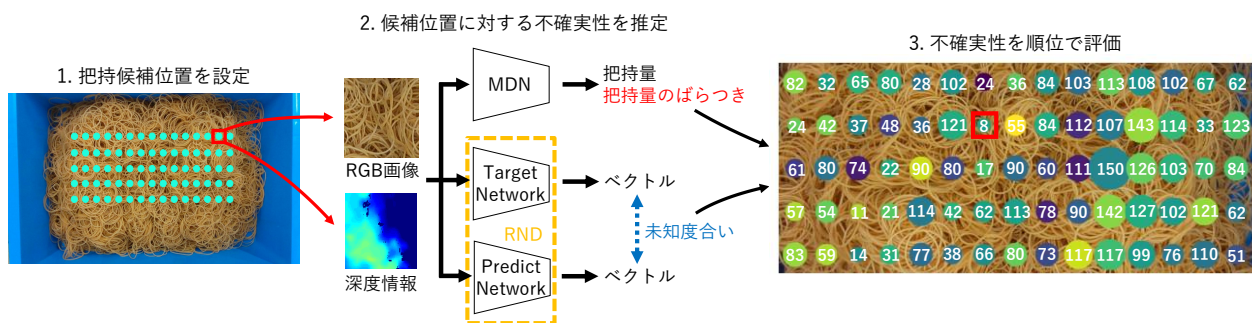


図 2: 把持位置選択の流れ



図 3: 評価実験で使した環境

3.2 未知度合いに基づいたミニバッチ作成

不確実性が低い領域を把持位置として選択する場合、不確実性が高い領域に対する予測性能は把持精度に影響を与えない。そこで、学習時に不確実性が高いデータの学習頻度を低く、不確実性が低いデータの学習頻度を高く設定することで、不確実性が低いデータに対する学習を促進する。不確実性としてRNDによる未知度合いを使用し、 i 番目のデータ x_i に対する未知度合い s_i の逆数 \tilde{s}_i を正規化した値を、ミニバッチ作成時のサンプリング確率 p_i とする。未知度合いに対する処理を式 (5)、サンプリング確率を式 (6) に示す。

$$\tilde{s}_i = \begin{cases} \frac{1}{s_i}, & \text{if } s_i \neq 0 \\ 0, & \text{otherwise} \end{cases} \quad (5)$$

$$p'_i = \frac{\tilde{s}_i}{\sum_j \tilde{s}_j} \quad \text{for each} \quad (6)$$

また，サンプリング確率 p'_i に対して，上限 p_{\max} と下限 p_{\min} を設定する．サンプリング確率の判定を式 (7) に示す．

$$p_i'' = \max(p_{\min}, \min(p_{\max}, p_i')) \quad (7)$$

その後，サンプリング確率の合計が 1 になるように正規化を再度行い，最終的なサンプリング確率とする．最終的なサンプリング確率を式 (8) に示す．

$$p_i = \frac{p_i''}{\sum_j p_j''} \quad \text{for each } i \quad (8)$$

このようにして，サンプリング確率の偏りを抑えつつ，未知度合いが低いデータを優先的に学習できるように調整する．本研究では，この未知度合いに基づいたサンプリング方法を UASampler と呼ぶ．

3.3 複数の不確実性を考慮した把持位置の選択

学習後のモデルを用いた把持位置の選択では、MDN が出力する把持量のばらつきと RND が出力する未知度合いの両方が低い領域を選択する。把持位置選択の流れを図 2 に示す。まず初めに、把持対象の入ったトレイ内に一定の間隔で把持の候補位置を設定する。次に、把持の候補位置を中心として正方形に切り抜いたカメラ画像と深度情報を MDN と RND に入力し、把持量と不確実性を予測する。MDN が出力する把持量のばらつきと RND が出力する未知度合いは、異なる不確実性の指標のため、値の範囲が異なる。そこで、各不確実性において小さい順で順位付けを行い、値の範囲を統一する。最後に、把持量のばらつきの順位と未知度合いの順位を足し合わせた値を各候補位置の評価結果とし、最も値の小さい候補位置を把持位置として選択する。把持位置の選択を式 (9) に示す。

$$\arg \min_i (R_{\text{MDN},i} + R_{\text{RND},i}) \quad (9)$$

表 1: 従来手法と提案手法の把持成功率 [%]

未知度合い	ばらつき	UASampler	$\pm 0.1g$	$\pm 0.5g$	$\pm 1.0g$	$\pm 1.5g$	$\pm 2.0g$	$\pm 2.5g$	$\pm 3.0g$
✓			7	14	29	45	54	58	73
	✓		1	11	23	38	51	61	73
✓	✓		3	<u>23</u>	<u>35</u>	<u>55</u>	<u>62</u>	<u>68</u>	<u>82</u>
✓	✓	✓	<u>6</u>	27	49	64	74	81	88

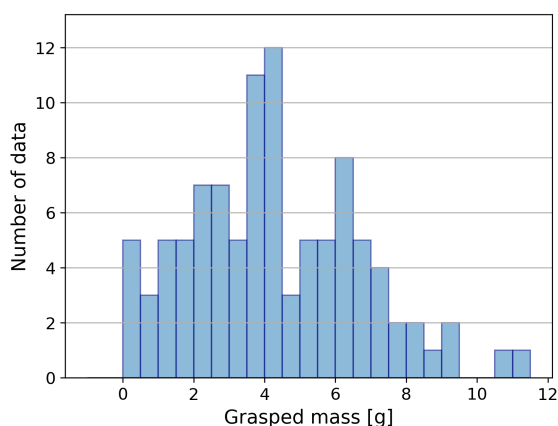


図 4: 収集したデータにおける把持量とデータ数

ここで, i は把持の候補位置, $R_{MDN,i}$ は把持量のばらつきの順位, $R_{RND,i}$ は未知度合いの順位である.

4 評価実験

本章では, 不確実性に基づいてピッキングロボットの把持位置を選択し, モデルが予測した把持量とピッキングロボットの把持量を比較することで, 従来手法と提案手法の把持精度を評価する. 評価実験で利用した環境を図 3 に示す. 把持対象の物体として物体間で絡まりが発生し小さい物体である輪ゴムを使用し, ピッキングロボットとして単腕, 4 軸の MyPalletizer を使用する. カメラ画像と深度情報は, RGB カメラと深度センサを搭載した Intel RealSense D435 [14] から取得する. 把持量の計測には, 0.01 g 単位の計測が可能なはかりを使用する.

4.1 把持データの収集と学習データの作成

把持データの収集プロセスは, 4 つのステップで構成される. まず, 把持前の状態をカメラ画像と深度情報として取得する. 次に, 把持位置 x, y をランダムに決定し, 把持深さ z を把持対象の表面から 20 mm 下として設定をし, 把持を行う. その後, 把持した物体をはかりまで移動し, 把持量の計測を行う. 把持と計測を 10 回繰り返した後に, ピッキングロボットが把持した

物体を人の手でトレイ内に戻す. このとき, トレイ内の把持対象の初期状態は, 場所によって高さに変化するように人の手で調整を行う. この収集プロセスを繰り返し, 100 個の把持データを収集した.

収集した把持データは, 把持位置を中心として正方形に切り抜いたカメラ画像と深度情報を入力データ, 把持量を正解データとして, 学習データとする. このとき, 深度情報はヒートマップ形式で表現した RGB 画像として使用し, 正解データとなる把持量は kg 単位で表現して使用する. また, カメラ画像と深度情報の切り抜きサイズはピッキングロボットの把持領域を全て含むことができる 140×140 ピクセルに設定する. 100 個の把持データにおける把持量とデータ数の関係を図 4 に示す. 横軸は把持量, 縦軸はデータ数を表す. 学習データは, 4.0 g から 4.5 g を中心としたガウス分布に近いデータである.

4.2 実験概要

本実験では, 100 個の学習データを用いて学習したモデルの把持精度を評価する. 評価対象として, 未知度合いのみを考慮した把持, 把持量のばらつきのみを考慮した把持, 未知度合いと把持量のばらつきの両方を考慮した把持, UASampler を用いて学習したモデルにおける未知度合いと把持量のばらつきの両方を考慮した把持の 4 パターンを使用する.

4.2.1 学習条件

各評価対象の学習条件は, 学習率を 0.001, エポック数を 2000, バッチサイズを 8, MDN のガウス分布の数 K を 1, UASampler における上限 p_{\max} を 0.05 (5%), 下限 p_{\min} を 0.001 (0.1%) とし, 最適化アルゴリズムとして NAdam [15] を使用する. UASampler を使用する場合, 200 エポック目から UASampler を適用する.

4.2.2 評価条件

把持の候補位置は, トレイ内で横 16mm, 縦 21mm の間隔で縦に 5 個, 横に 15 個の合計 75 個の位置を設



把持量のばらつき



未知度合い

図 5: 把持量のばらつきと未知度合いの傾向

定する．各候補位置に対して，候補位置を中心として正方形に切り抜いた 140×140 ピクセルのカメラ画像と深度情報を作成し，モデルにより予測を行って把持位置の選択を行う．把持性能は，モデルの予測把持量と実際の把持量の差がしきい値以下の場合に把持成功と判定して把持成功率を計算し，評価する．本実験では，把持成功率の計算時に 0.1 g から 3.0 g の範囲の合計 7 つのしきい値を使用する．各評価対象に対して 100 回の把持実験を行い，7 つのしきい値における把持成功率を比較する．

4.3 評価結果

4 つの評価対象の把持成功率を表 1 に示す．各成功率のしきい値において，太字は最も高い成功率，下線は 2 番目に高い成功率であることを表す．

2 つの不確実性を考慮した把持は，しきい値が 0.1 g の場合を除いた全てのしきい値において，1 つの不確実性のみを考慮した把持を上回る把持成功率となった．ある把持位置の選択時における把持量のばらつきと未知度合いを図 5 に示す．円の大きさは各不確実性の大きさを表し，白抜きの数字は不確実性を小さい順に順位付けした際の順位を表す．2 つの不確実性における各候補位置の順位に着目すると，把持量のばらつきと未知度合いで異なる順位の傾向となっている．これらのことから，把持位置の選択時に未知度合いと把持量のばらつきの両方を考慮することで高い把持成功率を達成したと考えられる．

UASampler を使用して学習したモデルを用いた 2 つの不確実性を考慮した把持は，しきい値が 0.1 g の場合を除いた全てのしきい値において，UASampler なしの場合を上回る把持成功率となった．このことから，UASampler を導入することで，未知度合いが低いデータの学習が促進され，高い把持成功率を達成したと考えられる．

5 おわりに

本研究では，不確実性に基づいたピッキングロボットの把持位置選択における把持精度の向上を目的として，

不確実性が低いデータの学習頻度を促進する学習戦略と，複数の観点の不確実性に基づいた把持位置選択を提案した．不確実性が低いデータの学習頻度の促進では，ミニバッチ作成時に未知度合いが低い学習データのサンプリング確率が高くなるように調整する UASampler を設計した．複数の観点の不確実性に基づいた把持位置選択では，未知度合いと把持量のばらつきの順位の和が小さい候補位置を把持位置として選択した．評価実験では，物体間で絡まりが発生する輪ゴムを把持対象として使用し，単腕，4 軸のピッキングロボットを用いて把持成功率の評価を行った．実験結果より，UASampler の有効性と複数の不確実性を考慮した把持位置選択の有効性を確認した．今後は，提案手法における把持成功率改善の分析，目標把持量を設定した場合における提案手法の有効性の調査，輪ゴム以外の物体における把持成功率の評価を行う予定である．

参考文献

- [1] Kuniyuki Takahashi, Wilson Ko, Avinash Ummadisingu, and Shin ichi Maeda. Uncertainty-aware self-supervised target-mass grasping of granular foods. In *IEEE International Conference on Robotics and Automation*, pages 2620–2626, 2021.
- [2] Kuniyuki Takahashi, Naoki Fukaya, and Avinash Ummadisingu. Target-mass grasping of entangled food using pre-grasping & post-grasping. *IEEE Robotics and Automation Letters*, 7(2):1222–1229, 2022.
- [3] Corey Goldfeder, Matei Ciocarlie, Dang Hao, and Peter K. Allen. The columbia grasp database. In *IEEE International Conference on Robotics and Automation*, pages 1710–1716, 2009.
- [4] Jeannette Bohg, Antonio Morales, Tamim Asfour, and Danica Kragic. Data-driven grasp synthesis—a survey. *IEEE Transactions on Robotics*, 30(2):289–309, 2014.
- [5] David Silver, Aja Huang, Chris J. Madison, Arthur Guez, Laurent Sifre, George

- van den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, Sander Dieleman, Dominik Grewe, John Nham, Nal Kalchbrenner, Ilya Sutskever, Timothy Lillicrap, Madeleine Leach, Koray Kavukcuoglu, Thore Graepel, and Demis Hassabis. Mastering the game of go with deep neural networks and tree search. *Nature*, 529:484–489, 2016.
- [6] Sergey Levine, Peter Pastor, Alex Krizhevsky, Julian Ibarz, and Deirdre Quillen. Learning hand-eye coordination for robotic grasping with deep learning and large-scale data collection. *International journal of robotics research*, 37(4-5):421–436, 2018.
- [7] Volodymyr Mnih, Adria Puigdomenech Badia, Mehdi Mirza, Alex Graves, Timothy Lillicrap, Tim Harley, David Silver, and Koray Kavukcuoglu. Asynchronous methods for deep reinforcement learning. In *International Conference on Machine Learning*, pages 1928–1937, 2016.
- [8] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.
- [9] Jeffrey Mahler, Jacky Liang, Sherdil Niyaz, Michael Laskey, Richard Doan, Xinyu Liu, Juan Aparicio Ojea, and Ken Goldberg. Dexnet 2.0: Deep learning to plan robust grasps with synthetic point clouds and analytic grasp metrics. In *Robotics: Science and Systems*, 2017.
- [10] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. *Communications of the ACM*, 60(6):84–90, 2017.
- [11] Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba, and Pieter Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 23–30, 2017.
- [12] Liang Cheng, Prashant Singh, and Francesco Ferranti. Transfer learning-assisted inverse modeling in nanophotonics based on mixture density networks. *IEEE Access*, 12:55218–55224, 2024.
- [13] Yuri Burda, Harrison Edwards, Amos Storkey, and Oleg Klimov. Exploration by random network distillation. In *International Conference on Learning Representations*, 2019.
- [14] Tetsuri Sonoda, John Sweetser, Trinh Quang Khuong, Shirit Brook, Anders Grunnet-Jepsen, and Rev. High-speed capture mode of intel® realsense™ depth camera d435. 2020.
- [15] Qikun Zhang, Yuzhi Zhang, Yanling Shao, Mengqi Liu, Jianyong Li, Junling Yuan, and Ruifang Wang. Boosting adversarial attacks with nadam optimizer. *Electronics*, 2023.