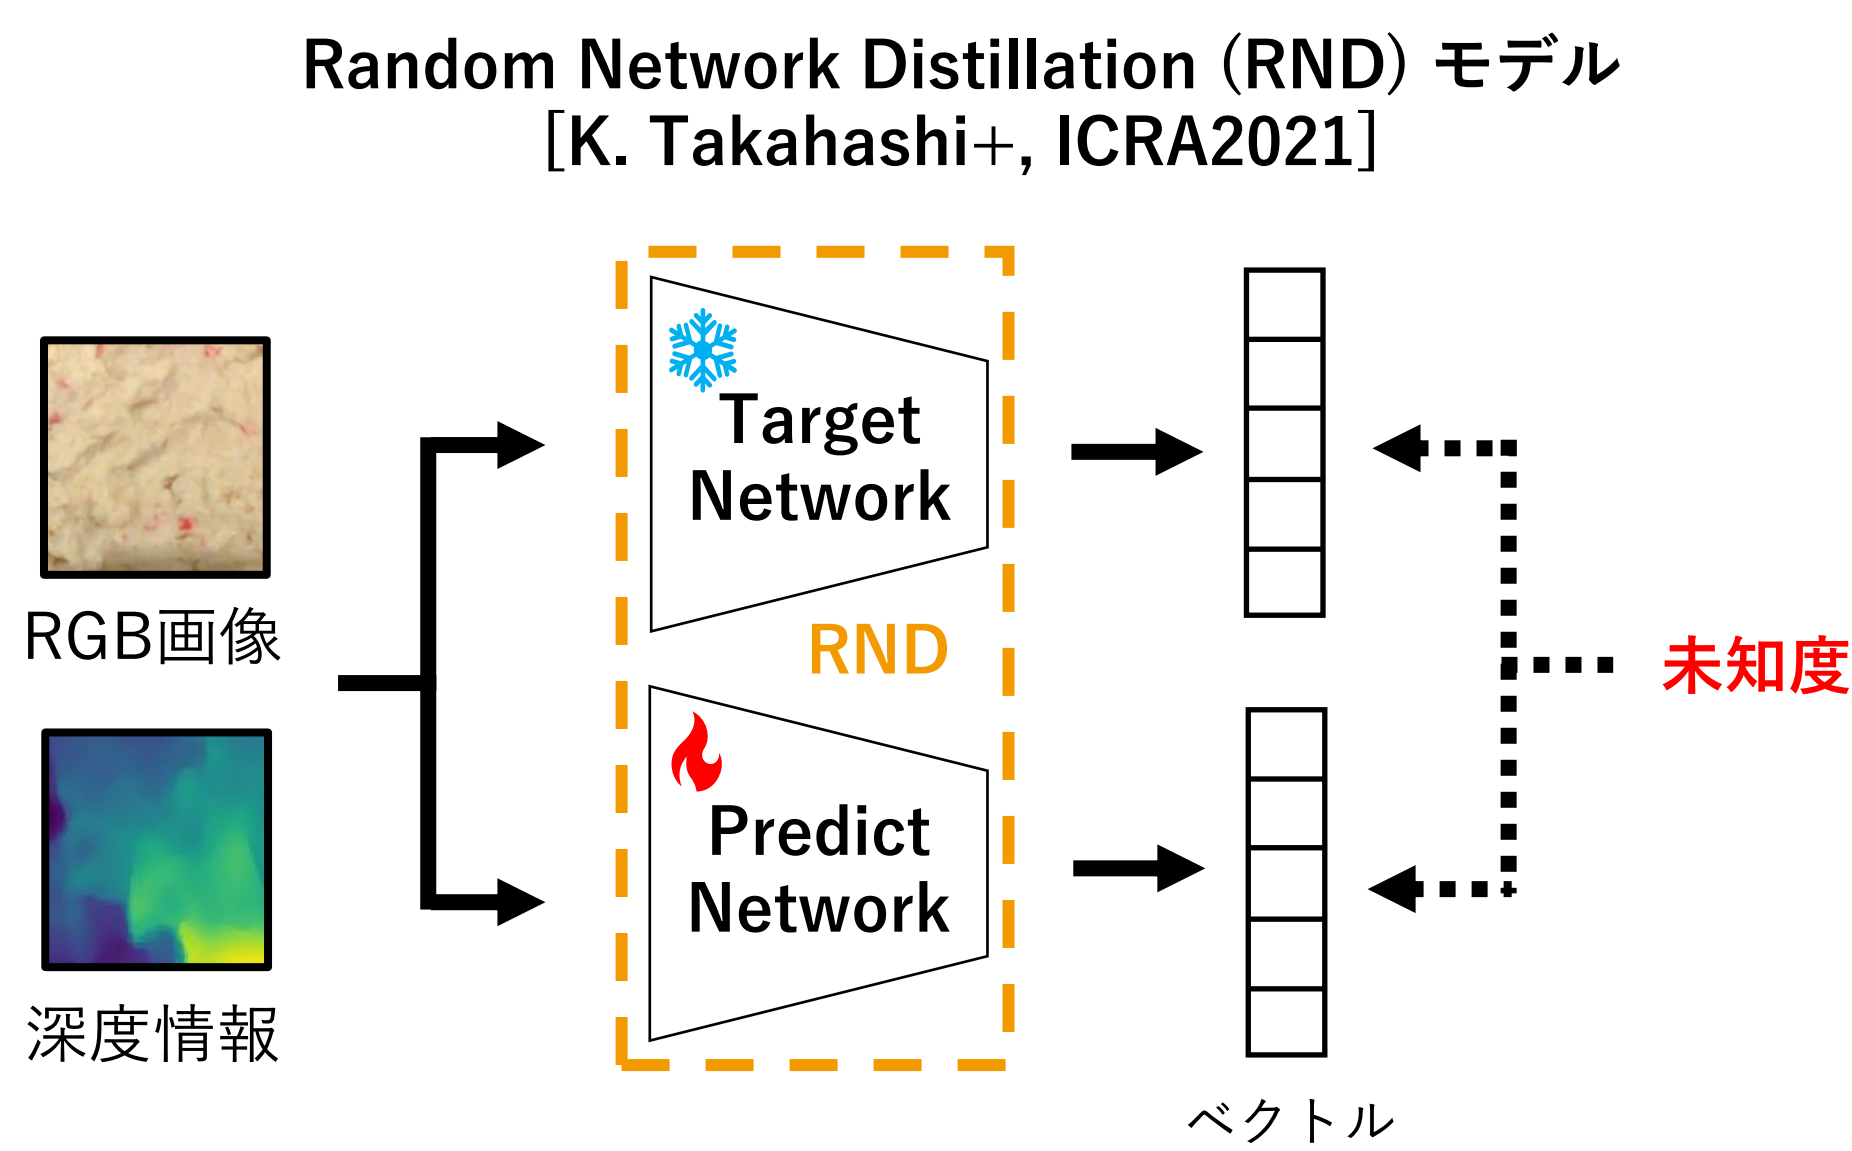


■ 研究背景

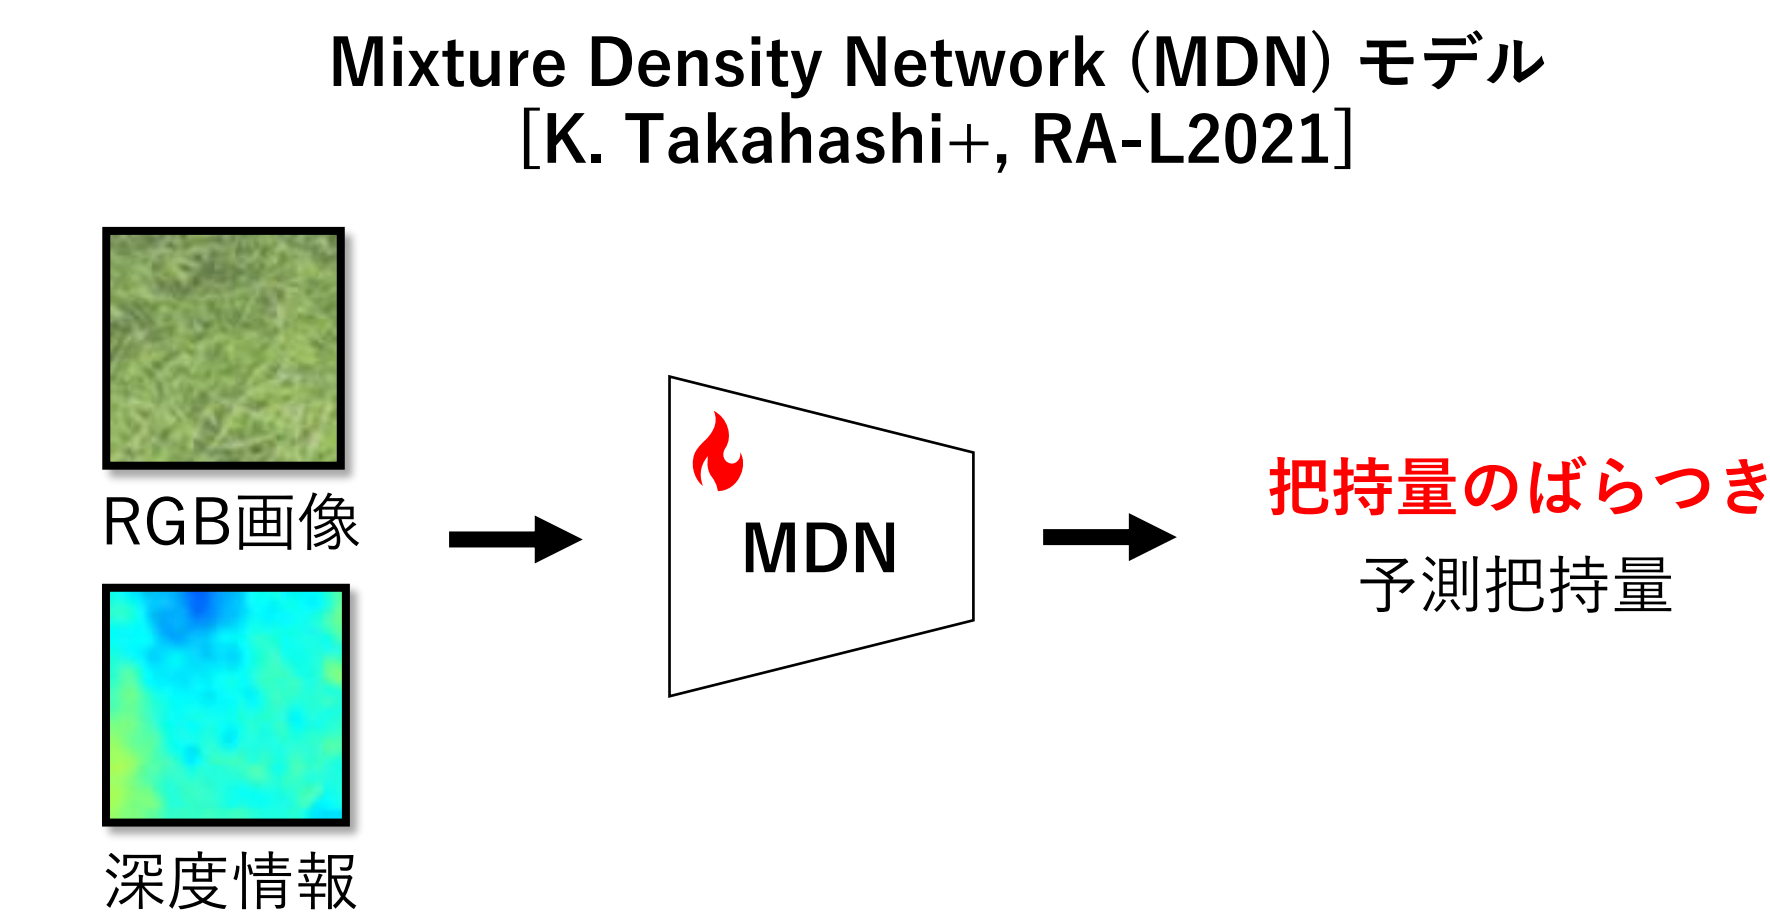
- 食品製造工場における惣菜等の詰め込み作業は人手依存
→ ピッキングロボットによる自動化が求められている
- 惣菜等の多くが不定形状であり、把持戦略の事前設計が困難
→ データドリブンな深層学習を用いて把持戦略を決定
- 不確実性の考慮により少数の学習データで高精度な把持を実現

■ 従来手法

- 学習データの不足に基づく不確実性を考慮した把持手法
 - Random Network Distillation (RND)を使用
 - Target Networkの出力を予測するようにPredict Networkを学習
 - 未知度が低い領域を把持位置として選択



- 食品特有の形状に基づく不確実性を考慮した把持手法
 - Mixture Density Network (MDN) を使用
 - 複数の把持量の可能性をガウス分布としてモデル化
 - ばらつきが低い領域を把持位置として選択



■ 従来手法の課題

- 1つの観点のみに基づいた不確実性の考慮
 - 学習不足や食品同士の絡まり合い等、複数の観点で存在
- 推論時のみ不確実性を考慮
 - 不確実性が低い領域を把持する戦略は、不確実性が高い領域に関する学習が把持精度に影響しない

■ 提案手法

- 複数の観点に基づいて不確実性が低い領域を把持位置として選択
→ 学習時に不確実性が低い領域を優先的に学習

モデル構造

- 入力：RGB画像 + 深度情報
- 出力：MDN → 把持量 + **ばらつき**, RND → **未知度**

学習方法

- 損失関数： $L = L_{MDN} + L_{RND}$

$$L_{MDN} = -\log \left[\sum_{k=1}^K \Pi_k \phi(O_{mass} | \mu_k, \sigma_k) \right]$$

ϕ : ガウス関数, μ_k : 平均値, σ_k : 標準偏差, O_{mass} : 正解把持量

$$L_{RND} = \|v_{target} - v_{predict}\|^2$$

v_{target} : Target Networkの出力, $v_{predict}$: Predict Networkの出力

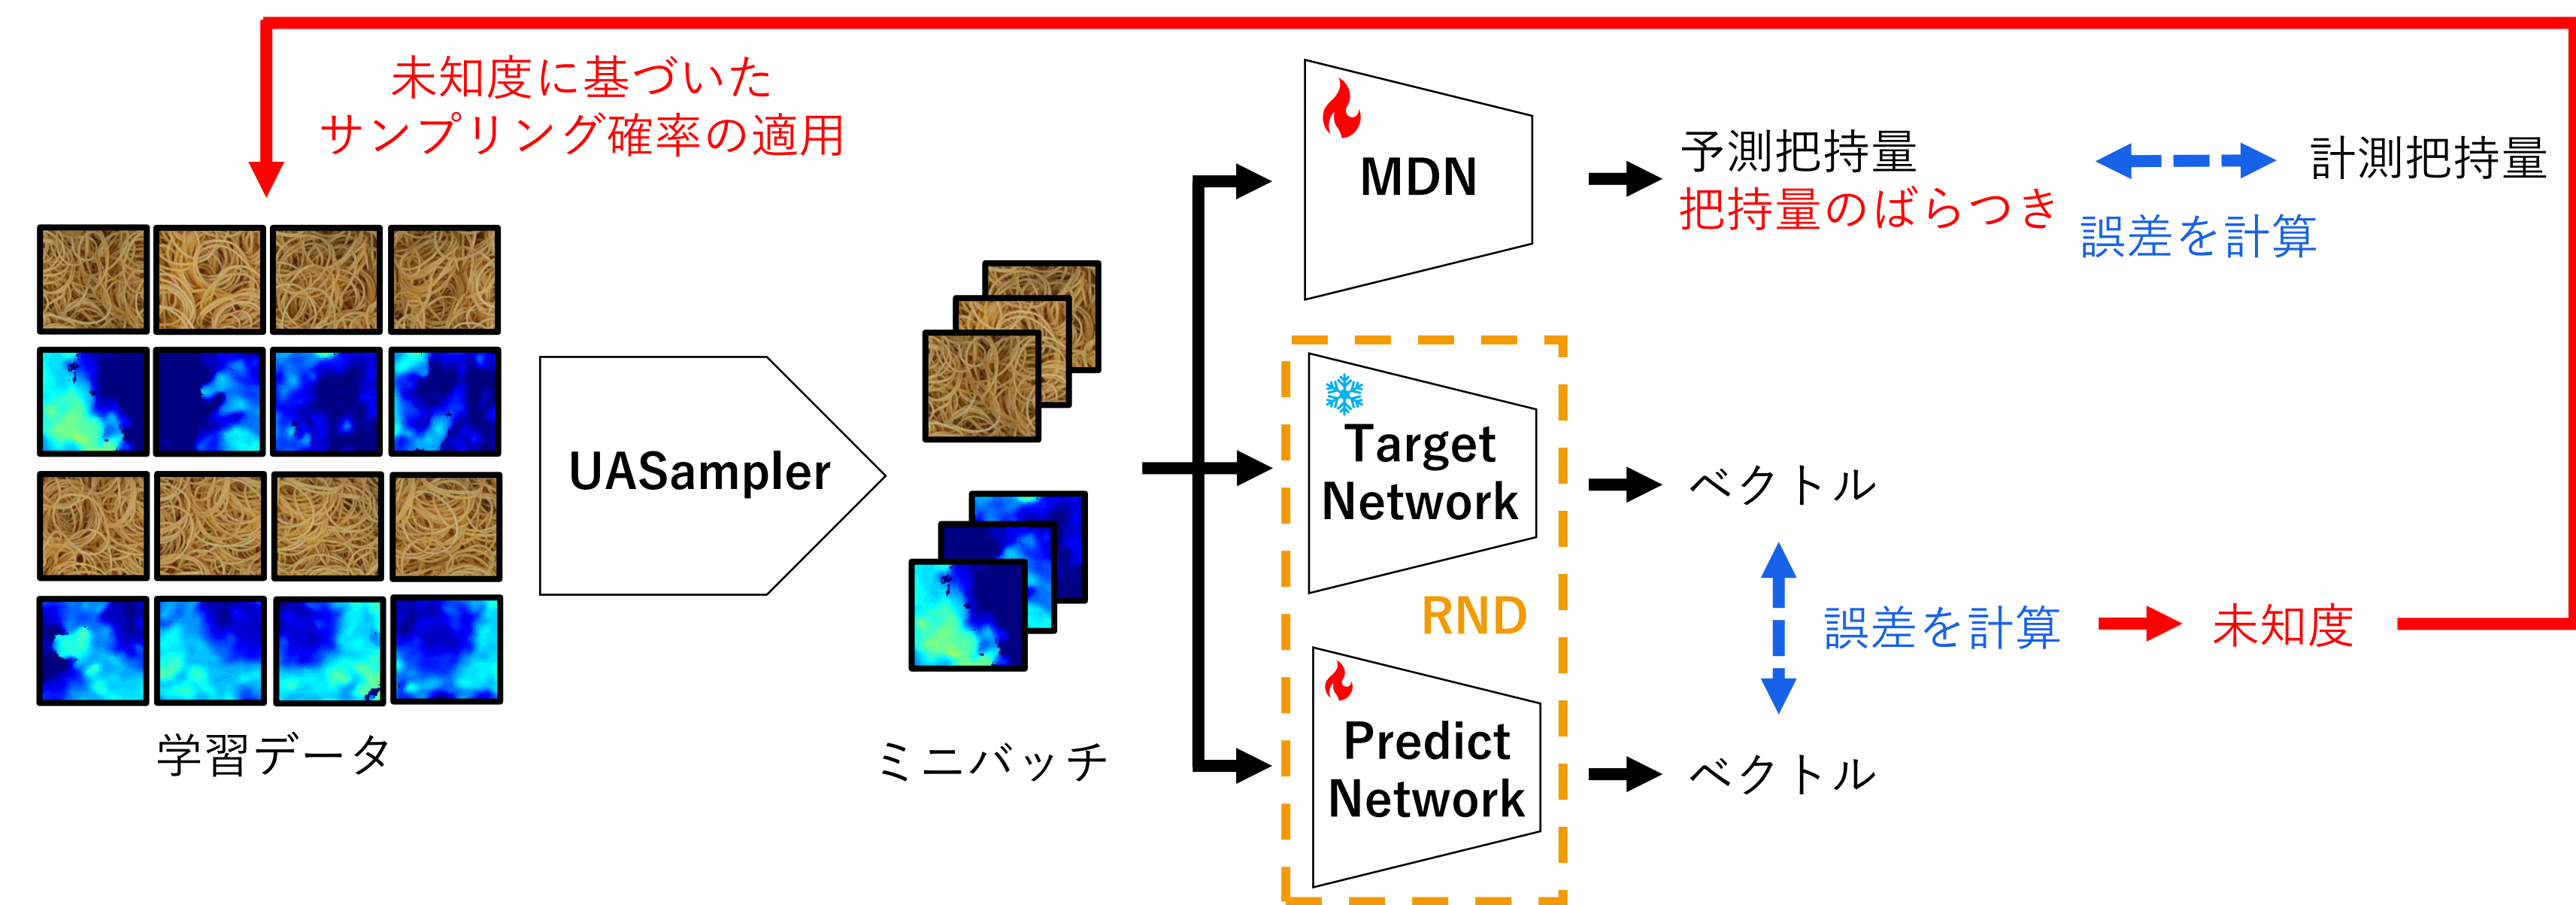
- 未知度に基づくサンプリング方法のUASamplerを提案

$$\tilde{s}_i = \begin{cases} \frac{1}{s_i} & \text{if } s_i \neq 0 \\ 0 & \text{otherwise} \end{cases} \quad \text{for each } i \quad p_i = \frac{\tilde{s}_i}{\sum_j \tilde{s}_j} \quad \text{for each } i$$

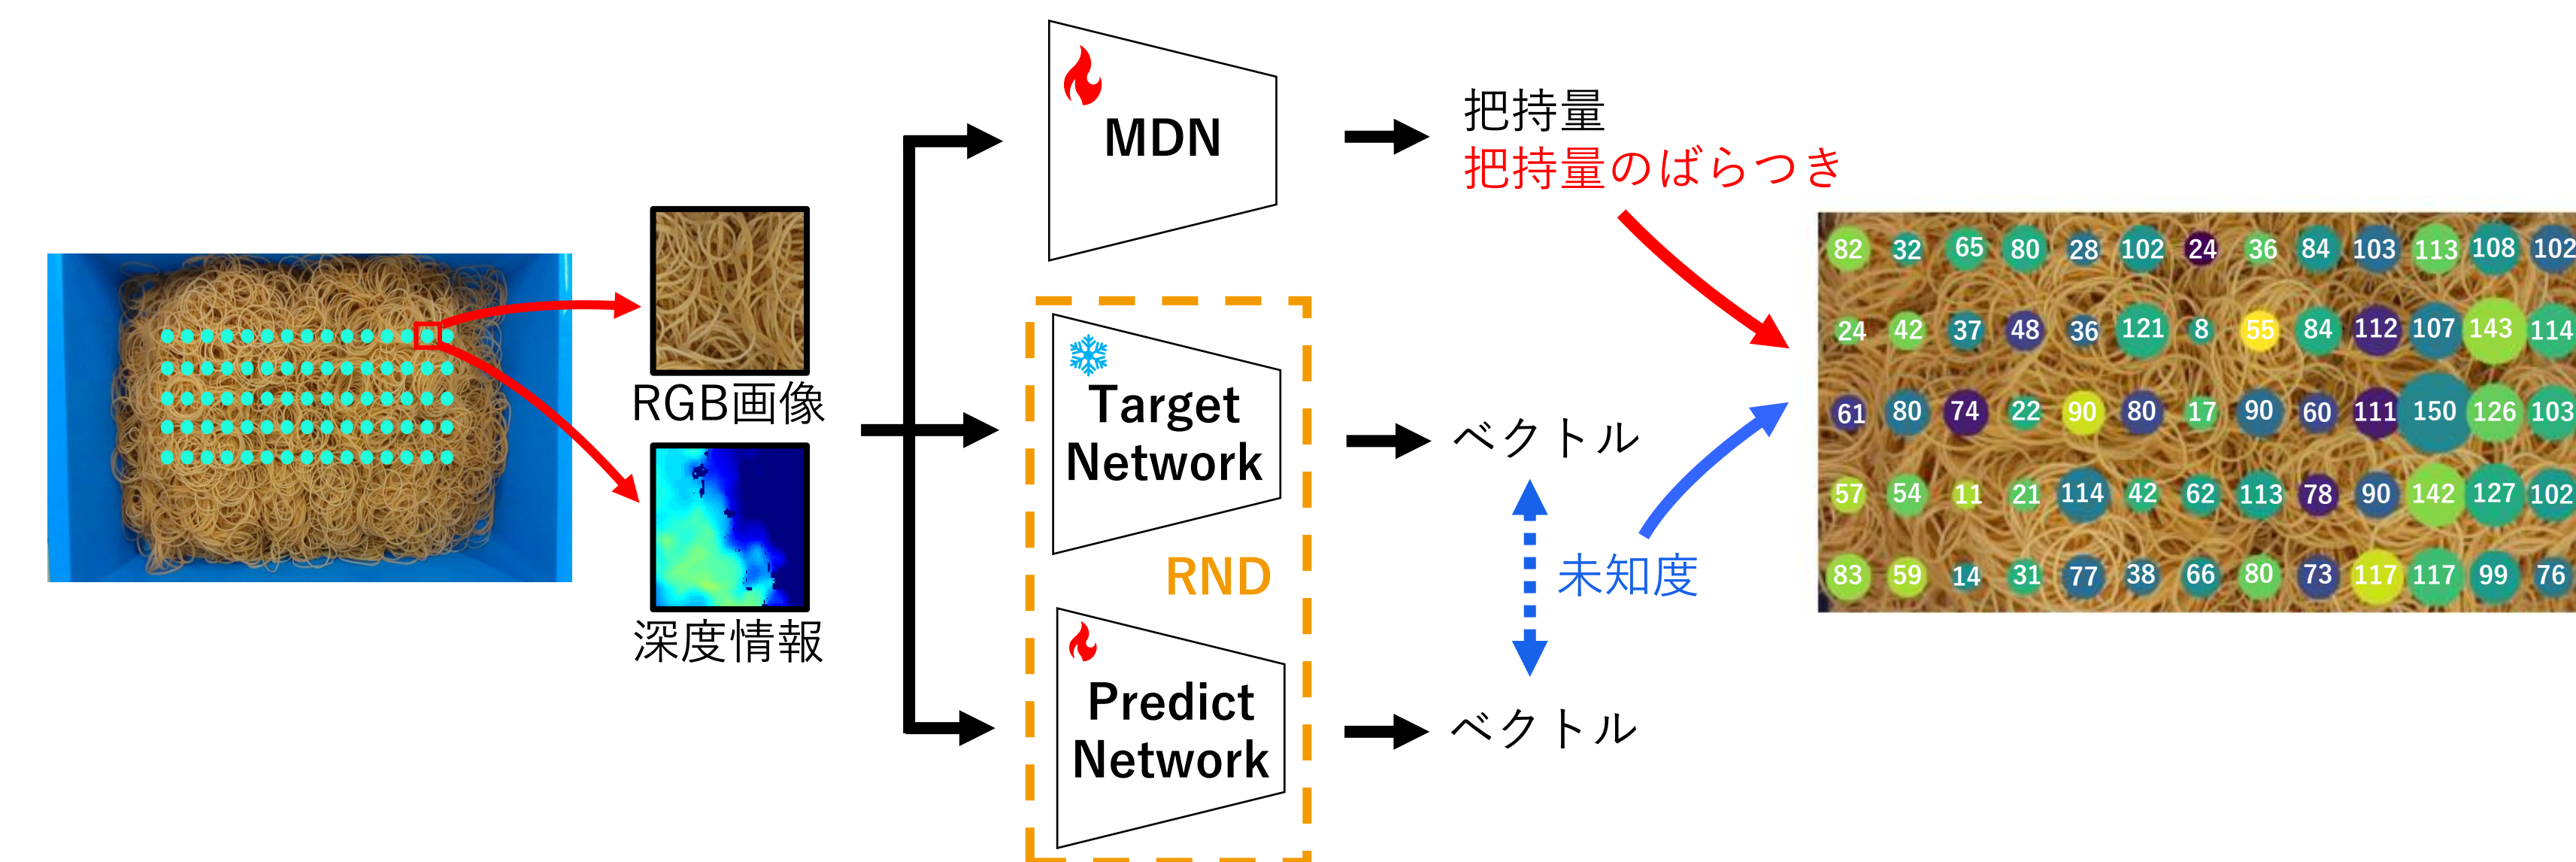
s_i : i 番目のデータに対する未知度, \tilde{s}_i : 未知度の逆数, p_i : サンプリング確率

推論方法

- 未知度と把持量のばらつきを考慮した把持位置選択
 - 複数の把持候補位置を設定
 - 候補位置に対する不確実性を推定
 - 未知度とばらつきの順位の和が最小の位置を選択




モデル構造と学習方法



把持位置選択の流れ

■ 実験環境

- ピッキングロボット：単腕・4軸のMyPalletizer
- カメラ：RGBカメラと深度センサを搭載したRealSense
- はかり：0.01g単位の計測が可能なもの
- 輪ゴム：絡まりが発生しやすい疑似食品



- 学習データの作成（100個収集）
 - 入力データ：140×140pxにクロップしたRGB画像と深度情報
 - 正解データ：ピッキングロボットの把持量

■ 評価実験

- 評価方法
 - 把持候補の位置としてトレイ内で75個の把持位置を設定
 - 各候補位置に対してモデルの予測を行い把持位置を選択
 - 予測把持量と計測把持量の差が閾値以下で把持成功と判定

		把持成功率 [%]						
未知度	ばらつき	UASampler	±0.5g	±1.0g	±1.5g	±2.0g	±2.5g	±3.0g
✓			14	29	45	54	58	73
	✓		11	23	38	51	61	73
✓	✓		23	35	55	62	68	82
✓	✓	✓	27	49	64	74	81	88

- 未知度と把持量のばらつきの両方を考慮する有効性を確認
- UASamplerを導入する有効性を確認